

**Universidad Nacional**

Sede Regional Brunca — Campus Pérez Zeledón

**Curso:** Inteligencia Artificial

# **Inteligencia Artificial en Diagnóstico Médico**

Proyecto de Investigación

**Integrantes:**

Angel Stward Segura Méndez

**Docente:**

Prof. Pablo Andrés Venegas Elizondo

Marzo, 2026

# Índice

|                                                                   |           |
|-------------------------------------------------------------------|-----------|
| <b>1. Introducción</b>                                            | <b>2</b>  |
| <b>2. Marco Conceptual</b>                                        | <b>3</b>  |
| 2.1. Conceptos Fundamentales . . . . .                            | 3         |
| 2.1.1. Redes neuronales artificiales (ANN) . . . . .              | 3         |
| 2.1.2. Redes Neuronales Convolucionales (CNN) . . . . .           | 3         |
| 2.1.3. Diagnóstico Asistido por Computadora (CAdE/CADx) . . . . . | 4         |
| 2.2. Arquitecturas Relevantes . . . . .                           | 4         |
| 2.3. Métricas . . . . .                                           | 4         |
| <b>3. Estado del Arte</b>                                         | <b>6</b>  |
| 3.1. Análisis de Literatura . . . . .                             | 6         |
| 3.2. Comparación de Enfoques . . . . .                            | 6         |
| 3.3. Discusión de Resultados . . . . .                            | 6         |
| <b>4. Aplicaciones Reales</b>                                     | <b>8</b>  |
| 4.1. Casos de Implementación . . . . .                            | 8         |
| <b>5. Limitaciones y Desafíos Éticos</b>                          | <b>9</b>  |
| 5.1. Sesgo Algorítmico . . . . .                                  | 9         |
| 5.2. Problemas de Escalabilidad . . . . .                         | 9         |
| 5.3. Consideraciones Regulatorias y Éticas . . . . .              | 9         |
| <b>6. Conclusiones</b>                                            | <b>11</b> |
| 6.1. Síntesis de hallazgos . . . . .                              | 11        |
| 6.2. Valoración crítica del equipo . . . . .                      | 11        |
| 6.3. Perspectivas futuras del área . . . . .                      | 11        |

# 1. Introducción

La inteligencia artificial (IA), específicamente la rama de aprendizaje profundo (Deep Learning), está revolucionando actualmente la detección de enfermedades por medio de imágenes en varias ramas de la medicina como la radiología, ortopedia, dermatología y oftalmología, entre otras, en las que se utilizan tecnologías avanzadas de imagen para diagnosticar, pronosticar y tratar enfermedades. Años atrás, los médicos analizaban estas imágenes manualmente o utilizando diagnósticos asistidos por computadora (CAD); sin embargo, no ayudaban lo suficiente y frecuentemente resultaba mejor realizar todo el proceso manual debido a limitaciones en su rendimiento. No obstante, la llegada del Deep Learning cambió por completo la situación con algoritmos como las redes neuronales convolucionales (CNN), que han sido la base de muchas arquitecturas utilizadas para identificar enfermedades y que, en diferentes sectores de la medicina, han rendido de manera comparable o incluso superior a especialistas experimentados. Hoy en día, la FDA (Food and Drug Administration), agencia federal principal responsable de regular dispositivos o tecnologías médicas, ha autorizado ya una cantidad considerable de modelos para su utilización en hospitales para que funcionen como copilotos bajo supervisión de especialistas.

Las CNN llamaron mucho la atención cuando en 2012 la red convolucional AlexNet superó totalmente a los algoritmos rivales en la competición anual de ImageNet. Estos algoritmos avanzados, capaces de capturar patrones complejos en imágenes para detectar patologías en el cuerpo humano, han sido utilizados para crear arquitecturas con propósitos específicos dentro de la medicina como lo son U-Net, 3D U-Net, V-Net, Attention U-Net y GoogLeNet, entre muchas otras.

Las CNN han ocasionado un gran avance en el ámbito de los CAD, demostrando un excelente rendimiento. El entendimiento de cómo están compuestas estas CNN y su respectivo impacto en la automatización de tareas complejas es de suma importancia para la creación de mejores soluciones que ayuden a evitar, mitigar o facilitar el diagnóstico de enfermedades. Técnicamente, las CNN eliminan la necesidad de extraer manualmente características (handcrafted features), un proceso que no era óptimo y dependía en gran medida de la experiencia humana.

En esta investigación se busca transmitir conocimientos acerca del Deep Learning y su utilización en el ámbito médico con evidencia científica probada; también se responderá a preguntas sobre cómo ha impactado el flujo de trabajo de profesionales en el sector de la radiología, cómo medimos la eficiencia de estos algoritmos avanzados, por supuesto, revisaremos los desafíos y aspectos éticos que deben ser considerados para implementar esta tecnología en la práctica clínica.

## 2. Marco Conceptual

### 2.1. Conceptos Fundamentales

#### 2.1.1. Redes neuronales artificiales (ANN)

Modelos computacionales inspirados en el funcionamiento del cerebro humano, su elemento principal son las neuronas. Las ANN se caracterizan por una asamblea de cientos de estas neuronas artificiales (unidades de computación básicas). El entrenamiento consiste en un par de señales como input y también se les presentan una serie de salidas deseadas, imitando como el cerebro depende de estímulos externos para aprender.

#### 2.1.2. Redes Neuronales Convolucionales (CNN)

Las CNN están diseñadas para imitar la corteza visual humana, procesar datos bidimensionales o tridimensionales. Las CNN son la evolución de las ANN para procesamiento de imágenes. Su importancia técnica radica en:

- Eliminación de la necesidad de extraer características manualmente
- Aprendizaje de jerarquías de patrones (bordes, líneas, formas, texturas y patologías)
- Procesamiento eficiente de datos espaciales

**Arquitectura y Capas Principales** El funcionamiento de las CNN está compuesto por varias capas especializadas (Seeram & Kanade, 2024, p. 28):

1. **Capa de entrada:** Recibe la imagen, donde los píxeles se consideran neuronas.
2. **Capa de convolución:** Filtros que se deslizan sobre la imagen generando mapas de características.
3. **Función de Activación (ReLU):** Introduce no linealidad convirtiendo valores negativos en cero.
4. **Capa de agrupación (Pooling):** Reduce la dimensionalidad conservando las características más importantes.
5. **Capas totalmente conectadas:** Unifican la información para razonamiento de alto nivel.
6. **Capa de salida:** Asigna una probabilidad a cada categoría diagnóstica mediante funciones como “Softmax”.

Durante el entrenamiento, la imagen pasa por todas las capas generando una predicción que se compara con el resultado esperado, proporcionado por radiólogos expertos; los errores se propagan de nuevo en la red para ir ajustando la salida hasta que el error sea mínimo.

### 2.1.3. Diagnóstico Asistido por Computadora (CAdE/CADx)

Es el marco operativo donde se aplica la IA en los hospitales. Los sistemas CAD actuales han evolucionado de esquemas rígidos a plataformas basadas en Deep Learning que actúan como “segunda opinión” para el radiólogo, ayudando a:

- Reducir errores de observación
- Mejorar la eficiencia del flujo de trabajo
- Aumentar la precisión diagnóstica

## 2.2. Arquitecturas Relevantes

**AlexNet** La red que inició el interés masivo al superar a todos los algoritmos en la competencia ImageNet.

**U-Net** La base perfecta para la segmentación de imágenes médicas debido a su estructura simétrica y “conexiones de salto” que recuperan información espacial precisa.

**ResNet** Introdujo conexiones residuales que permiten entrenar redes extremadamente profundas sin pérdida de precisión.

## 2.3. Métricas

La precisión por sí sola puede ser engañosa en diagnósticos médicos. Un modelo que siempre marca a los pacientes como sanos tendría alta precisión si la mayoría lo están, pero fallaría en detectar a los enfermos. Por ello se utilizan métricas complementarias basadas en la matriz de confusión: verdaderos positivos (VP), verdaderos negativos (VN), falsos positivos (FP) y falsos negativos (FN).

**Sensibilidad** Mide qué tan bien el modelo identifica los casos positivos:

$$\text{Sensibilidad} = \frac{\text{VP}}{\text{VP} + \text{FN}}$$

**Especificidad** Mide la capacidad de etiquetar correctamente a pacientes sanos:

$$\text{Especificidad} = \frac{VN}{VN + FP}$$

Ambas métricas se integran en la Curva ROC (Receiver Operating Characteristic), cuya área bajo la curva (AUC) resume la eficiencia del modelo en un valor único entre 0 y 1. Un AUC de 1.0 representa la perfección.

### 3. Estado del Arte

#### 3.1. Análisis de Literatura

El análisis de la literatura científica reciente muestra una evolución clara hacia la optimización de arquitecturas y la eficiencia operativa:

- Shin et al. (2016) evaluaron el uso de arquitecturas como AlexNet y GoogLeNet en radiología torácica, demostrando que el aprendizaje por transferencia desde bases de datos generales (ImageNet) compensa eficazmente la escasez de imágenes médicas etiquetadas.
- Menchú López (2025) realizó una revisión sistemática que sitúa a la radiología como la especialidad líder en adopción de IA, con un 88.2% de las autorizaciones de la FDA, destacando que los algoritmos de deep learning ya igualan o superan la precisión de especialistas en tareas de cribado de cáncer de mama y gliomas.
- Pérez-Pelegri et al. (2023) profundizaron en la segmentación cardíaca, validando la arquitectura U-Net como el estándar para delimitar estructuras anatómicas y resaltando que el uso de modelos de conjunto (ensembles) es la mejor estrategia para evitar el sobreajuste (overfitting) en datos clínicos limitados.

#### 3.2. Comparación de Enfoques

La siguiente tabla compara los enfoques de los estudios fundamentales analizados:

Cuadro 1: Comparación de enfoques metodológicos en la literatura consultada

| Criterio            | Shin et al. (2016)                      | Menchú (2025)                              | López | Pérez-Pelegri et al. (2023)             |
|---------------------|-----------------------------------------|--------------------------------------------|-------|-----------------------------------------|
| <b>Modelo</b>       | GoogLeNet / AlexNet (Transfer Learning) | CNN / IA Generativa / NLP                  |       | U-Net y Modelos de Conjunto (Ensembles) |
| <b>Dataset</b>      | ILD (Pulmón) y ganglios linfáticos      | Revisión de 1,016 dispositivos autorizados |       | MRI Cardíaca (Eje corto)                |
| <b>Precisión</b>    | 90.2 % de precisión en clasificación    | AUC: 93.2 % (Gliomas) y 89.6 % (Mama)      |       | Alto coeficiente Dice en segmentación   |
| <b>Limitaciones</b> | Escasez de datos médicos anotados       | Sesgos algorítmicos y «AI drift» (deriva)  |       | Sobreajuste en bases de datos pequeñas  |

#### 3.3. Discusión de Resultados

Los resultados reportados confirman que la IA no solo es precisa, sino también operativamente transformadora. Estudios clínicos en entornos reales, como el de Northwestern

Medicine, han demostrado mejoras de productividad de hasta un 40 % en la generación de informes radiológicos sin pérdida de calidad diagnóstica. Además, se ha probado que las CNN pueden identificar patologías críticas, como el neumotórax, en tiempo real antes de que el radiólogo abra el estudio, priorizando el triaje clínico.

## 4. Aplicaciones Reales

### 4.1. Casos de Implementación

La implementación de la inteligencia artificial en el entorno clínico ha pasado de ser una promesa teórica a una realidad documentada con evidencia sólida. Un caso destacado es el de Northwestern Medicine, que implementó un sistema de IA generativa en tiempo real a través de 11 hospitales, analizando casi 24,000 reportes radiológicos en 2024 para generar automáticamente informes personalizados con un 95 % de completación. En el área de la oftalmología, la colaboración entre Google DeepMind y el Moorfields Eye Hospital permitió el desarrollo de modelos capaces de detectar la retinopatía diabética y la degeneración macular con una precisión comparable a la de expertos humanos. En neurorradiología, el sistema Aidoc ha demostrado una eficacia crítica en la detección temprana de hemorragias intracraneales, actuando como un sistema de triaje automático. Por otro lado, investigadores de la Universidad de Stanford han validado algoritmos de deep learning que detectan la neumonía en radiografías de tórax con un rendimiento que rivaliza con radiólogos experimentados. En oncología, plataformas como IBM Watson for Oncology asisten a los especialistas analizando literatura médica y datos del paciente para sugerir planes de tratamiento personalizados para el cáncer. Finalmente, la empresa Arterys utiliza IA para analizar resonancias magnéticas cardíacas, logrando reducir el tiempo de interpretación de varias horas a solo unos minutos.

## 5. Limitaciones y Desafíos Éticos

### 5.1. Sesgo Algorítmico

El sesgo algorítmico surge cuando los sistemas de IA favorecen sistemáticamente a ciertos grupos sobre otros debido a deficiencias en los datos de entrenamiento. En radiología, esto se manifiesta principalmente a través del sesgo de recolección de datos, donde los modelos entrenados exclusivamente en una demografía específica (ej. hombres blancos de mediana edad) pueden omitir signos de enfermedad en mujeres o personas de otros orígenes étnicos. Asimismo, existe un sesgo geográfico, donde algoritmos con alta precisión en hospitales urbanos con tecnología de punta fallan al ser implementados en áreas rurales con equipos diferentes. El sesgo también puede originarse en la anotación, si los radiólogos que etiquetan las imágenes tienen criterios subjetivos divergentes que el modelo acaba heredando.

### 5.2. Problemas de Escalabilidad

Escalar estas soluciones presenta desafíos estructurales y económicos significativos. Técnicamente, el entrenamiento de redes profundas requiere una inmensa potencia computacional, dependiendo fuertemente de procesadores gráficos (GPU) de alto costo. Existe un cuello de botella crítico en la disponibilidad de datasets masivos y bien anotados, ya que el etiquetado médico es una tarea laboriosa que requiere expertos experimentados. Además, la heterogeneidad de los sistemas digitales hospitalarios dificulta la integración; muchas instituciones operan con infraestructuras obsoletas o sistemas legados que no interactúan fácilmente con las plataformas modernas de IA. Finalmente, para las clínicas pequeñas, los costos de implementación (adquisición, integración y capacitación) pueden ser prohibitivos, creando una brecha digital en la atención sanitaria.

### 5.3. Consideraciones Regulatorias y Éticas

La regulación y la ética constituyen los pilares para una implementación responsable. Organismos como la FDA regulan la IA como “Software como Dispositivo Médico” (SaMD), exigiendo validaciones rigurosas a través de vías como la autorización 510(k) o la aprobación pre-mercado (PMA). Un aspecto ético fundamental es la privacidad de los datos, obligando a cumplir estrictamente con normativas como HIPAA y GDPR para proteger la información sensible del paciente mediante protocolos de anonimización y cifrado.

En cuanto a la responsabilidad legal, persiste el dilema sobre quién asume el error en caso de un diagnóstico fallido: si el clínico que usó la herramienta o la empresa desarrolladora del software. Por ello, se promueve el concepto de Inteligencia Aumentada,

donde la IA actúa como un copiloto que complementa, pero no reemplaza, la autonomía y el juicio del médico. Finalmente, es imperativo garantizar el consentimiento informado, asegurando que los pacientes comprendan cómo y por qué se utiliza la IA en su proceso diagnóstico.

## 6. Conclusiones

### 6.1. Síntesis de hallazgos

La presente investigación confirma que el aprendizaje profundo ha dejado de ser una tecnología experimental para convertirse en una herramienta transformadora con evidencia sólida de eficacia clínica en el diagnóstico médico. El hallazgo más significativo es la capacidad de las CNN para igualar o incluso superar el rendimiento humano en tareas específicas de diagnóstico radiológico, con una precisión (AUC) del 93.2% en la clasificación de gliomas y del 89.6% en la detección de cáncer de mama. Arquitecturas como U-Net se han consolidado como el estándar de oro para la segmentación, mientras que el aprendizaje por transferencia ha permitido superar la barrera de la escasez de datos médicos anotados. El marco regulatorio refleja esta madurez, con más de 1,000 dispositivos médicos basados en IA autorizados por la FDA, de los cuales el 88.2% pertenecen al panel de radiología.

### 6.2. Valoración crítica del equipo

A pesar de los éxitos rotundos en precisión, la implementación masiva de la IA en salud enfrenta desafíos éticos y técnicos que requieren una vigilancia crítica. El problema de la “Caja Negra” persiste como una barrera fundamental para la confianza clínica, ya que la opacidad en el razonamiento interno de los algoritmos dificulta la validación médica de sus decisiones. Consideramos imperativo que la IA se adopte bajo el concepto de Inteligencia Aumentada, funcionando como un “copiloto” que complementa el juicio del especialista en lugar de reemplazar su autonomía diagnóstica.

Es preocupante observar que muchos modelos heredan sesgos algorítmicos debido a la falta de diversidad en los datos de entrenamiento, lo que podría perpetuar desigualdades en la atención de poblaciones marginadas. Asimismo, el fenómeno de la “Deriva de la IA”, donde el rendimiento de un modelo decae con el tiempo debido a cambios en los equipos o protocolos hospitalarios, exige que las instituciones desarrollen marcos de gobernanza de IA que incluyan un monitoreo continuo y protocolos de recalibración periódica. La integración no será exitosa si no se resuelve primero la heterogeneidad de los sistemas digitales hospitalarios, que a menudo operan con infraestructuras legadas incompatibles con las plataformas de IA modernas.

### 6.3. Perspectivas futuras del área

El campo de la IA en medicina se dirige hacia una mayor transparencia, versatilidad y colaboración interinstitucional. Las fronteras de investigación actuales se centran en las siguientes tendencias:

1. IA Explicable: El desarrollo de sistemas que permitan a los médicos comprender qué regiones de la imagen influyeron en el diagnóstico (como mapas de atención) es una prioridad para eliminar el efecto de caja negra.
2. Modelos Fundacionales: Se prevé la transición de modelos especializados en una sola tarea hacia modelos generales de IA médica, entrenados en conjuntos masivos y multimodales (X-rays, MRI y CT simultáneamente) para realizar diagnósticos transversales en múltiples especialidades.
3. Procesamiento de Lenguaje Natural (NLP): La integración de notas clínicas textuales con datos de imagen mediante NLP permitirá generar reportes automatizados y personalizados, ofreciendo una visión holística del paciente.
4. Aprendizaje Federado: Esta tecnología permitirá entrenar algoritmos en redes de múltiples hospitales sin que los datos privados de los pacientes salgan de su institución de origen, resolviendo simultáneamente problemas de privacidad y escasez de datos.
5. Realidad Aumentada (AR) y Virtual (VR): Estas herramientas mejorarán la visualización y navegación durante cirugías mínimamente invasivas y el planeamiento preoperatorio.

En conclusión, la IA en radiología ha superado la etapa de promesa y se encuentra en una fase de expansión donde la colaboración multidisciplinaria entre radiólogos, desarrolladores y reguladores será el factor decisivo para asegurar una implementación equitativa, segura y efectiva.

## Referencias

- Menchú López, W. E. (2025). Inteligencia Artificial en Radiología: Una Revisión Narrativa del Estado Actual, Aplicaciones Clínicas y Perspectivas Futuras [Centro Universitario de Occidente - USAC]. *Revista Médica CUNOC*. <https://cienciacunoc.org>
- Pérez-Pelegri, M., Monmeneu, J. V., López-Lereu, M. P., & Moratal, D. (2023). Convolutional Neural Networks for Segmentation in Short-Axis Cine Cardiac Magnetic Resonance Imaging: Review and Considerations. En Ş. Öztürk (Ed.), *Convolutional Neural Networks for Medical Image Processing Applications* (pp. 1-33). CRC Press. <https://doi.org/10.1201/9781003215141>
- Seeram, E., & Kanade, V. (2024). *Artificial Intelligence in Medical Imaging Technology: An Introduction*. Springer Nature Switzerland AG. <https://doi.org/10.1007/978-3-031-64049-0>
- Shin, H.-C., Roth, H. R., Gao, M., Lu, L., Xu, Z., Nogues, I., Yao, J., Mollura, D., & Summers, R. M. (2016). Deep Convolutional Neural Networks for Computer-Aided Detection: CNN Architectures, Dataset Characteristics and Transfer Learning. *IEEE Transactions on Medical Imaging*, 35(5), 1285-1298. <https://doi.org/10.1109/TMI.2016.2528162>