

**Universidad Nacional**

Sede Regional Brunca — Campus Pérez Zeledón

**Curso:** Inteligencia Artificial

# **Inteligencia Artificial en Diagnóstico Médico**

Proyecto de Investigación

**Integrantes:**

Angel Stward Segura Méndez

**Docente:**

Prof. Pablo Andrés Venegas Elizondo

Marzo, 2026

# Índice

|                                                                   |           |
|-------------------------------------------------------------------|-----------|
| <b>1. Introducción</b>                                            | <b>2</b>  |
| <b>2. Marco Conceptual</b>                                        | <b>3</b>  |
| 2.1. Conceptos Fundamentales . . . . .                            | 3         |
| 2.1.1. Aprendizaje Automático y Deep Learning . . . . .           | 3         |
| 2.1.2. Redes Neuronales Convolucionales (CNN) . . . . .           | 3         |
| 2.1.3. Diagnóstico Asistido por Computadora (CAdE/CADx) . . . . . | 4         |
| 2.2. Arquitecturas Relevantes . . . . .                           | 4         |
| 2.3. Métricas . . . . .                                           | 5         |
| <b>3. Estado del Arte</b>                                         | <b>6</b>  |
| 3.1. Análisis de Literatura . . . . .                             | 6         |
| 3.2. Comparación de Enfoques . . . . .                            | 6         |
| 3.3. Discusión de Resultados . . . . .                            | 6         |
| 3.4. Tendencias Actuales . . . . .                                | 6         |
| <b>4. Aplicaciones Reales</b>                                     | <b>7</b>  |
| 4.1. Casos de Implementación . . . . .                            | 7         |
| 4.2. Sectores y Tecnologías . . . . .                             | 7         |
| 4.3. Impacto Práctico . . . . .                                   | 8         |
| <b>5. Limitaciones y Desafíos Éticos</b>                          | <b>9</b>  |
| 5.1. Riesgos Técnicos . . . . .                                   | 9         |
| 5.2. Sesgo Algorítmico . . . . .                                  | 9         |
| 5.3. Problemas de Escalabilidad . . . . .                         | 9         |
| 5.4. Consideraciones Regulatorias y Éticas . . . . .              | 9         |
| <b>6. Conclusiones</b>                                            | <b>10</b> |

# 1. Introducción

La inteligencia artificial (IA), específicamente la rama de aprendizaje profundo (Deep Learning), está revolucionando actualmente la detección de enfermedades por medio de imágenes en varias ramas de la medicina como la radiología, ortopedia, dermatología y oftalmología, entre otras, en las que se utilizan tecnologías avanzadas de imagen para diagnosticar, pronosticar y tratar enfermedades. Años atrás, los médicos analizaban estas imágenes manualmente o utilizando diagnósticos asistidos por computadora (CAD); sin embargo, no ayudaban lo suficiente y frecuentemente resultaba mejor realizar todo el proceso manual debido a limitaciones en su rendimiento. No obstante, la llegada del Deep Learning cambió por completo la situación con algoritmos como las redes neuronales convolucionales (CNN), que han sido la base de muchas arquitecturas utilizadas para identificar enfermedades y que, en diferentes sectores de la medicina, han rendido de manera comparable o incluso superior a especialistas experimentados. Hoy en día, la FDA (Food and Drug Administration), agencia federal principal responsable de regular dispositivos o tecnologías médicas, ha autorizado ya una cantidad considerable de modelos para su utilización en hospitales para que funcionen como copilotos bajo supervisión de especialistas.

Las CNN llamaron mucho la atención cuando en 2012 la red convolucional AlexNet superó totalmente a los algoritmos rivales en la competición anual de ImageNet. Estos algoritmos avanzados, capaces de capturar patrones complejos en imágenes para detectar patologías en el cuerpo humano, han sido utilizados para crear arquitecturas con propósitos específicos dentro de la medicina como lo son U-Net, 3D U-Net, V-Net, Attention U-Net y GoogLeNet, entre muchas otras.

Las CNN han ocasionado un gran avance en el ámbito de los CAD, demostrando un excelente rendimiento. El entendimiento de cómo están compuestas estas CNN y su respectivo impacto en la automatización de tareas complejas es de suma importancia para la creación de mejores soluciones que ayuden a evitar, mitigar o facilitar el diagnóstico de enfermedades. Técnicamente, las CNN eliminan la necesidad de extraer manualmente características (handcrafted features), un proceso que no era óptimo y dependía en gran medida de la experiencia humana.

En esta investigación se busca transmitir conocimientos acerca del Deep Learning y su utilización en el ámbito médico con evidencia científica probada; también se responderá a preguntas sobre cómo ha impactado el flujo de trabajo de profesionales en el sector de la radiología específicamente, cómo medimos la eficiencia de estos algoritmos avanzados, cuáles arquitecturas han sentado las bases para la mayoría de CNN y, por supuesto, revisaremos los desafíos y aspectos éticos que deben ser considerados para implementar esta tecnología en la práctica clínica.

## 2. Marco Conceptual

### 2.1. Conceptos Fundamentales

#### 2.1.1. Aprendizaje Automático y Deep Learning

Deep learning se define como el subcampo del aprendizaje automático (machine learning) en donde se utilizan redes neuronales artificiales estructuradas en diferentes capas para modelar y comprender patrones complejos.

#### 2.1.2. Redes Neuronales Convolucionales (CNN)

Arquitectura específica que ha revolucionado el área. Las CNN están diseñadas para imitar la corteza visual humana y procesar datos tipo matriz en donde el orden y posición son fundamentales, como en una imagen. Su importancia técnica radica en:

- Eliminación de la necesidad de extraer características manualmente
- Aprendizaje de jerarquías de patrones (bordes, líneas, formas, texturas y patologías)
- Procesamiento eficiente de datos espaciales

**Arquitectura y Capas Principales** El funcionamiento de las CNN está compuesto por varias capas especializadas:

1. **Capa de entrada:** Recibe la imagen. Los píxeles se consideran neuronas.
2. **Capa de convolución:** Utiliza filtros o kernels (pequeñas ventanas matemáticas) que se deslizan sobre la imagen. Después de varias multiplicaciones y sumas, el resultado es una cuadrícula bidimensional conocida como mapa de características.
3. **Función de Activación (ReLU):** Se aplica generalmente una unidad lineal rectificadora (ReLU) después de cada convolución. Esta capa introduce no linealidad al sistema, convirtiendo los valores negativos en cero, permitiendo a la red aprender patrones mucho más complejos.
4. **Capa de agrupación (Pooling layer):** Se encarga del down-sampling o reducción de dimensionalidad. El método más común es el Max Pooling, que selecciona solo el valor máximo de una región, conservando las características más importantes mientras reduce el costo computacional y el riesgo de sobreajuste.
5. **Capas totalmente conectadas:** Unifican la información de las capas anteriores. Cada neurona se conecta con todas las de la capa anterior para realizar razonamiento de alto nivel.

6. **Capa de salida:** Utiliza funciones como “Softmax” para asignar una probabilidad a cada categoría diagnóstica.

**Extracción Jerárquica y Automática de Características** Las CNN logran su efectividad a través de la extracción jerárquica de características. Como lo describe la literatura especializada:

“En el aprendizaje profundo, la computadora tiene muchas capas, como capas de detectives. Los primeros detectives observan cosas simples, como líneas rectas y curvas. Luego, los siguientes detectives observan cosas más complicadas, como bucles o líneas inclinadas. Finalmente, los últimos detectives juntan todas sus pistas y pueden decir qué número es” (Seeram & Kanade, 2024, p. 28, traducción propia).

**Proceso de Entrenamiento** El proceso de entrenamiento sucede cuando la imagen pasa por todas las capas, generando la salida (predicción) que se compara con el resultado esperado, proporcionado por radiólogos expertos, seguidamente los errores encontrados se pasan de nuevo en la red para así ir ajustando la salida hasta que el error sea mínimo.

### 2.1.3. Diagnóstico Asistido por Computadora (CAdE/CADx)

Es el marco operativo donde se aplica la IA en los hospitales. Los sistemas CAD actuales han evolucionado de esquemas rígidos a plataformas basadas en Deep Learning que actúan como “segunda opinión” para el radiólogo, ayudando a:

- Reducir errores de observación
- Mejorar la eficiencia del flujo de trabajo
- Aumentar la precisión diagnóstica

## 2.2. Arquitecturas Relevantes

**AlexNet** La red que inició el interés masivo al superar a todos los algoritmos en la competencia ImageNet.

**U-Net** La base perfecta para la segmentación de imágenes médicas debido a su estructura simétrica y “conexiones de salto” que recuperan información espacial precisa.

**ResNet** Introdujo conexiones residuales que permiten entrenar redes extremadamente profundas sin pérdida de precisión.

## 2.3. Métricas

La precision en el caso de diagnosticos medicos utilizando Deep learning puede ser engañosa, por ejemplo, pensemos en un modelo CNN que siempre marca a los pacientes como sanos sin importar si estan enfermos, si el 95 porciento de los pacientes son sanos entonces el modelo tendria un 95 porciento de precision pero tambien marcara ese 5 porciento restante como sano, seria preciso pero fallaria en detectar a los pacientes enfermos, para evitar este problema se explicaran conceptos como la sensibilidad, especificidad, Curva ROC (Receiver Operating Characteristic), AUC(Area under de curve). Primeramente se mostrara como se clasifica si un modelo CNN clasifica correctamente o incorrectamente pacientes.

- **Verdadero positivo (VP):** El modelo correctamente predijo que el paciente esta enfermo.
- **Verdadero negativo (VN):** El modelo correctamente predijo que el paciente no esta enfermo.
- **Falso positivo (FP):** El modelo incorrectamente predijo que el paciente esta enfermo.
- **Falso negativo (FN):** El modelo incorrectamente predijo que el paciente no esta enfermo.

**Sensibilidad** Es la medida de que tan bien el modelo puede identificar todos los casos verdaderos positivos y su formula es esta:

$$\text{Sensibilidad} = \frac{VP}{VP + FN}$$

**Especificidad** Es la capacidad del clasificador de etiquetar correctamente a pacientes como sanos:

$$\text{Sensibilidad} = \frac{VN}{VN + FP}$$

La sensibilidad y especificidad son utilizados para ROC (receiver operating characteristic) que es una representacion grafica del rendimiento de un modelo en todos los valores posibles de especificidad y sensibilidad y esto hace posible encontrar el AUC (Area under the curve), valor unico entre 0 y 1 que resume la eficiencia del modelo. Un AUC de 1.0 representa la clasificacion perfecta.

### **3. Estado del Arte**

#### **3.1. Análisis de Literatura**

#### **3.2. Comparación de Enfoques**

#### **3.3. Discusión de Resultados**

#### **3.4. Tendencias Actuales**

## 4. Aplicaciones Reales

Casos concretos de implementación

### 4.1. Casos de Implementación

La implementación de la inteligencia artificial en el entorno clínico ha pasado de ser una promesa teórica a una realidad documentada con evidencia sólida. Un caso destacado es el de Northwestern Medicine, que implementó un sistema de IA generativa en tiempo real a través de 11 hospitales, analizando casi 24,000 reportes radiológicos en 2024 para generar automáticamente informes personalizados con un 95 % de completación. En el área de la oftalmología, la colaboración entre Google DeepMind y el Moorfields Eye Hospital permitió el desarrollo de modelos capaces de detectar la retinopatía diabética y la degeneración macular con una precisión comparable a la de expertos humanos. En neurorradiología, el sistema Aidoc ha demostrado una eficacia crítica en la detección temprana de hemorragias intracraneales, actuando como un sistema de triaje automático. Por otro lado, investigadores de la Universidad de Stanford han validado algoritmos de deep learning que detectan la neumonía en radiografías de tórax con un rendimiento que rivaliza con radiólogos experimentados. En oncología, plataformas como IBM Watson for Oncology asisten a los especialistas analizando literatura médica y datos del paciente para sugerir planes de tratamiento personalizados para el cáncer. Finalmente, la empresa Arterys utiliza IA para analizar resonancias magnéticas cardíacas, logrando reducir el tiempo de interpretación de varias horas a solo unos minutos. Sectores industriales o tecnológicos

### 4.2. Sectores y Tecnologías

La IA se aplica de manera transversal en múltiples sectores del ecosistema de salud, utilizando diversas tecnologías de vanguardia:

- Sectores de Aplicación:
  - Hospitales y Práctica Clínica: Es el sector principal donde se integran herramientas de diagnóstico asistido por computadora (CAD) para optimizar el triaje y la interpretación.
  - Telemedicina: Plataformas de IA facilitan el acceso a diagnósticos expertos en áreas rurales o desatendidas mediante el uso de dispositivos portátiles.
  - Industria Farmacéutica: Se utiliza el deep learning para la identificación de nuevos fármacos analizando estructuras moleculares y datos genéticos.

- Investigación y Educación: El uso de modelos fundacionales y gemelos digitales permite la simulación de patologías para el entrenamiento de nuevos profesionales.
- Tecnologías Integradas:
  - Dispositivos Médicos (SaMD): El software como dispositivo médico es regulado por la FDA, que ha autorizado más de 1,000 dispositivos con IA hasta finales de 2024, siendo la radiología el panel líder con el 88.2 de las autorizaciones.
  - Equipos de Imagenología: Escáneres de CT de última generación como TrueFidelity (GE) y AiCE (Canon) integran algoritmos de reconstrucción de imágenes por aprendizaje profundo para mejorar la calidad visual.
  - Dispositivos Wearables: Equipos como Fitbit o Garmin utilizan algoritmos para el monitoreo remoto y la detección de anomalías cardíacas en tiempo real.

Impacto práctico

### 4.3. Impacto Práctico

El impacto real de la IA en la medicina se manifiesta en mejoras tangibles tanto para el sistema sanitario como para el paciente. En términos de eficiencia operativa, se han documentado mejoras de productividad de hasta un 40 % en la finalización de reportes radiológicos sin comprometer la precisión. Clínicamente, la capacidad de identificar enfermedades en etapas nacientes, cuando son más tratables, representa una de las mayores ventajas, como se observa en el cribado de cáncer de mama donde la IA logra un AUC del 89.6 %. Otro impacto crítico es la optimización de la dosis de radiación; los algoritmos de IA permiten obtener imágenes de alta calidad diagnóstica utilizando dosis bajas (LDCT), reduciendo así los riesgos para el paciente. Además, la IA reduce la carga de tareas repetitivas y agotadoras para los especialistas, disminuyendo el riesgo de errores causados por la fatiga o la subjetividad humana. Finalmente, el uso de procesamiento de lenguaje natural (NLP) permite una mejor integración de las notas clínicas con los datos de imagen, facilitando una visión holística y personalizada de la salud del paciente.

## 5. Limitaciones y Desafíos Éticos

### 5.1. Riesgos Técnicos

Caja Negra (Black Box): Se refiere a la dificultad de interpretar el razonamiento interno del modelo, lo que impulsa la necesidad de IA Explicable (XAI) para generar confianza clínica. Sesgo Algorítmico: El riesgo de que la IA perpetúe desigualdades si los datos de entrenamiento no son diversos. Deriva de la IA (AI Drift): La posible degradación del rendimiento del modelo con el tiempo debido a cambios en los equipos o protocolos médicos

### 5.2. Sesgo Algorítmico

### 5.3. Problemas de Escalabilidad

### 5.4. Consideraciones Regulatorias y Éticas

## **6. Conclusiones**