



Universidad Nacional

Sede Regional Brunca — Campus Pérez Zeledón

Curso de Inteligencia Artificial

Proyecto de Investigación

Inteligencia Artificial en Diagnóstico Médico

Curso: Inteligencia Artificial

Profesor: Pablo Andrés Venegas Elizondo

Responsables: Angel Stward Segura Méndez

Fecha: Marzo, 2026

Índice

1. Introducción	3
2. Marco Conceptual	4
2.1. Conceptos Fundamentales	4
2.1.1. Redes neuronales artificiales (ANN)	4
2.1.2. Redes Neuronales Convolucionales (CNN)	4
2.2. ImageNet	5
2.2.1. Detección Asistida por Computadora (CAdE)	5
2.2.2. Diagnóstico Asistido por Computadora (CAdx)	5
2.3. Arquitecturas Relevantes	5
2.4. Métricas	6
3. Estado del Arte	7
3.1. Análisis de Literatura	7
3.2. Comparación de Enfoques	7
3.3. Discusión de Resultados	7
4. Aplicaciones Reales	8
4.1. Casos de Implementación	8
4.1.1. Viz.ai — Detección de Accidentes Cerebrovasculares	8
4.1.2. Mirai — Predicción de Riesgo de Cáncer de Mama	8
4.1.3. Aidoc — Hemorragia Intracraneal	9
4.1.4. Qure.ai — Nódulos Pulmonares	9
4.1.5. Shockmatrix — Triage en Trauma	9
5. Limitaciones y Desafíos Éticos	10
5.1. Sesgo y Generalización	10
5.2. Regulación e IA Adaptativa	10
5.3. Interpretabilidad y Confianza	10
5.4. Responsabilidad Legal	10
5.5. Escalabilidad	10
6. Conclusiones	11
6.1. Síntesis de hallazgos	11
6.2. Valoración crítica	11
6.3. Perspectivas futuras	11

1. Introducción

La inteligencia artificial (IA), específicamente la rama de aprendizaje profundo (Deep Learning), ha revolucionado la detección de enfermedades por medio de imágenes en varias ramas de la medicina como la radiología, ortopedia, dermatología y oftalmología, entre otras, en las que se utilizan tecnologías avanzadas de imagen para diagnosticar, pronosticar y tratar enfermedades. Años atrás, los médicos analizaban estas imágenes manualmente o utilizando diagnósticos asistidos por computadora (CAD); sin embargo, no ayudaban lo suficiente y frecuentemente resultaba mejor realizar todo el proceso manual debido a limitaciones en su rendimiento. No obstante, la llegada del Deep Learning cambió por completo la situación con algoritmos como las redes neuronales convolucionales (CNN), que han sido la base de muchas arquitecturas utilizadas para identificar enfermedades y que, en diferentes sectores de la medicina, han rendido de manera comparable o incluso superior a especialistas experimentados. Hoy en día, la FDA (Food and Drug Administration), agencia federal principal responsable de regular dispositivos o tecnologías médicas, ha autorizado 873 algoritmos de IA en radiología a mediados de 2025, con 115 aprobaciones adicionales solo en ese año y representando el 78 % de todas las autorizaciones de IA médica (Laurent, 2025). Estos modelos funcionan como copilotos bajo supervisión de especialistas.

Las CNN llamaron mucho la atención cuando en 2012 la red convolucional AlexNet superó totalmente a los algoritmos rivales en la competición anual de ImageNet. Estos algoritmos avanzados, capaces de capturar patrones complejos en imágenes para detectar patologías en el cuerpo humano, han sido utilizados para crear arquitecturas con propósitos específicos dentro de la medicina como lo son U-Net, 3D U-Net, V-Net, Attention U-Net y GoogLeNet, entre muchas otras.

Las CNN han ocasionado un gran avance en el ámbito de los CAD, demostrando un excelente rendimiento. El entendimiento de cómo están compuestas estas CNN y su respectivo impacto en la automatización de tareas complejas es de suma importancia para la creación de mejores soluciones que ayuden a facilitar el diagnóstico de enfermedades. Técnicamente, las CNN eliminan la necesidad de extraer manualmente características (handcrafted features), un proceso que no era óptimo y dependía en gran medida de la experiencia humana.

En esta investigación se busca transmitir conocimientos acerca del Deep Learning y su utilización en el ámbito médico con evidencia científica probada; también se responderá a preguntas sobre cómo ha impactado el flujo de trabajo de profesionales en el sector de la radiología, cómo medimos la eficiencia de estos algoritmos avanzados, por supuesto, revisaremos los desafíos y aspectos éticos que deben ser considerados para implementar esta tecnología en la práctica clínica.

2. Marco Conceptual

2.1. Conceptos Fundamentales

2.1.1. Redes neuronales artificiales (ANN)

Modelos computacionales inspirados en el funcionamiento del cerebro humano, su elemento principal son las neuronas. Las ANN se caracterizan por una asamblea de cientos de estas neuronas artificiales (unidades de computación básicas). El entrenamiento consiste en un par de señales como entrada y también se les presentan una serie de salidas deseadas, imitando como el cerebro depende de estímulos externos para aprender.

2.1.2. Redes Neuronales Convolucionales (CNN)

Las CNN están diseñadas para imitar la corteza visual humana y procesar datos bidimensionales o tridimensionales. Las CNN son la evolución de las ANN para procesamiento de imágenes. Su importancia técnica radica en:

- Eliminación de la necesidad de extraer características manualmente
- Aprendizaje de jerarquías de patrones (bordes, líneas, formas, texturas y patologías)
- Procesamiento eficiente de datos espaciales

Arquitectura y Capas Principales El funcionamiento de las CNN está compuesto por varias capas especializadas (Seeram & Kanade, [2024](#), p. 28):

1. **Capa de entrada:** Recibe la imagen, donde los píxeles se consideran neuronas.
2. **Capa de convolución:** Filtros que se deslizan sobre la imagen generando mapas de características.
3. **Función de Activación (ReLU):** Introduce no linealidad convirtiendo valores negativos en cero.
4. **Capa de agrupación (Pooling):** Reduce la dimensionalidad conservando las características más importantes.
5. **Capas totalmente conectadas:** Unifican la información para razonamiento de alto nivel.
6. **Capa de salida:** Asigna una probabilidad a cada categoría diagnóstica mediante funciones como «Softmax».

Durante el entrenamiento, la imagen pasa por todas las capas generando una predicción que se compara con el resultado esperado, proporcionado por radiólogos expertos; los errores se propagan de nuevo en la red para ir ajustando la salida hasta que el error sea mínimo.

2.2. ImageNet

La base de datos más grande del mundo para el entrenamiento de redes neuronales convolucionales, contiene más de 1.2 millones de imágenes naturales clasificadas en más de 1000 categorías. ImageNet es la base para una competición anual ImageNet Large Scale Visual Recognition Challenge (ILSVRC), la cual se ha convertido en el estándar para evaluar el rendimiento de los algoritmos de reconocimiento de objetos a gran escala.

Los investigadores utilizan ImageNet para una técnica llamada transferencia de aprendizaje (transfer learning), que consiste en utilizar un modelo ya entrenado con el millón de imágenes de ImageNet. Como este modelo ya ha aprendido a detectar bastantes características fundamentales como bordes, texturas y formas, este modelo ya inteligente se adapta a una tarea médica específica (detectar tumores, neumonía, etc.), todo esto ahorra tiempo y recursos computacionales.

2.2.1. Detección Asistida por Computadora (CAdE)

Su objetivo principal es identificar y localizar anomalías en imágenes médicas. Se enfoca especialmente en reducir las tasas de falsos negativos, es decir, identificar tumores o lesiones que podrían pasar desapercibidos para el ojo humano.

2.2.2. Diagnóstico Asistido por Computadora (CADx)

Esto va un paso más allá de la simple detección, enfocándose en la evaluación y caracterización de las patologías ya identificadas. Por ejemplo, analiza la salida radiográfica para evaluar la probabilidad de que una lesión sea benigna o maligna. También intenta especificar el tipo de enfermedad, su severidad, estadio o la intervención recomendada.

2.3. Arquitecturas Relevantes

AlexNet La red que inició el interés masivo al superar a todos los algoritmos en la competencia ImageNet. Se considera una arquitectura poco profunda comparada con las actuales, pero fue la que demostró que entre más capas, mayor precisión (hasta cierto punto). Se utiliza mayormente para clasificación de imágenes, donde se asigna una etiqueta a la imagen (¿hay tumor o no?).

U-Net La base perfecta para la segmentación de imágenes médicas debido a su estructura simétrica en forma de U y «conexiones de salto» que recuperan información espacial

precisa. A diferencia de AlexNet, que predice una etiqueta para toda la imagen, U-Net realiza una predicción píxel por píxel, lo que permite delinear el contorno exacto de un objeto. Es la preferida para segmentación (proceso de identificar y delimitar con precisión píxeles) de imágenes.

ResNet AlexNet probó que entre más capas (más profundidad) mayor sería la precisión. Sin embargo, con modelos como VGGNet o GoogLeNet se observó que al aumentar la profundidad surgieron dos problemas: el desvanecimiento del gradiente y la degradación de la precisión. ResNet introdujo conexiones residuales que permiten que la información «salte» capas. Esto permitió entrenar redes extremadamente profundas sin pérdida de precisión. Se utiliza en tareas de alta precisión y reconocimiento de patrones complejos (reconocimiento de melanoma, radiografías de tórax, etc.).

2.4. Métricas

La precisión por sí sola puede ser engañosa en diagnósticos médicos. Un modelo que siempre marca a los pacientes como sanos tendría alta precisión si la mayoría lo están, pero fallaría en detectar a los enfermos. Por ello se utilizan métricas complementarias basadas en la matriz de confusión: verdaderos positivos (VP), verdaderos negativos (VN), falsos positivos (FP) y falsos negativos (FN).

Sensibilidad Mide qué tan bien el modelo identifica los casos positivos:

$$\text{Sensibilidad} = \frac{\text{VP}}{\text{VP} + \text{FN}}$$

Especificidad Mide la capacidad de etiquetar correctamente a pacientes sanos:

$$\text{Especificidad} = \frac{\text{VN}}{\text{VN} + \text{FP}}$$

Ambas métricas se integran en la Curva ROC (Receiver Operating Characteristic), cuya área bajo la curva (AUC) resume la eficiencia del modelo en un valor único entre 0 y 1. Un AUC de 1.0 representa la perfección.

3. Estado del Arte

3.1. Análisis de Literatura

El análisis de la literatura científica reciente muestra una evolución clara hacia la optimización de arquitecturas y la eficiencia operativa:

- Shin et al. (2016) evaluaron el uso de arquitecturas como AlexNet y GoogLeNet en radiología torácica, demostrando que el aprendizaje por transferencia desde bases de datos generales (ImageNet) compensa eficazmente la escasez de imágenes médicas etiquetadas.
- Menchú López (2025) realizó una revisión sistemática que sitúa a la radiología como la especialidad líder en adopción de IA, destacando que los algoritmos de deep learning ya igualan o superan la precisión de especialistas en tareas de cribado de cáncer de mama y gliomas.
- Laurent (2025) documenta que a mediados de 2025 existen 873 algoritmos de IA autorizados por la FDA en radiología, con una velocidad de aprobación de aproximadamente 115 nuevos algoritmos por año. Según una encuesta de la ESR (2024) con 572 radiólogos europeos, el 48 % ya utiliza herramientas de IA (frente al 20 % en 2018), aunque solo el 2 % de las prácticas radiológicas estadounidenses han integrado plenamente lecturas asistidas por IA.
- Pérez-Pelegri et al. (2023) profundizaron en la segmentación cardíaca, validando la arquitectura U-Net como el estándar para delimitar estructuras anatómicas y resaltando que el uso de modelos de conjunto (ensembles) es la mejor estrategia para evitar el sobreajuste (overfitting) en datos clínicos limitados.

3.2. Comparación de Enfoques

La siguiente tabla compara los enfoques de los estudios fundamentales analizados:

3.3. Discusión de Resultados

Los resultados confirman que la IA basada en CNN es operativamente transformadora: las CNN identifican patologías críticas como el neumotórax en tiempo real, priorizando el triaje antes de que el radiólogo abra el estudio. No obstante, persiste una brecha importante entre el avance tecnológico y la preparación profesional: el 80 % de los radiólogos europeos desconoce las regulaciones vigentes para dispositivos de IA médica y ningún LLM ha sido aprobado por la FDA para uso clínico (Laurent, 2025).

Cuadro 1: Comparación de enfoques metodológicos en la literatura consultada

Criterio	Shin et al. (2016)	Menchú López (2025)	Ló-pez (2025)	Pérez-Pelegrí et al. (2023)	Laurent (2025)
Modelo	GoogLeNet / AlexNet (Transfer Learning)	CNN / IA Generativa / NLP		U-Net y Modelos de Conjunto (Ensembles)	Viz.ai, Mirai, Aidoc, GPT-4V
Dataset	ILD (Pulmón) y ganglios linfáticos	Revisión de 1,016 dispositivos autorizados		MRI Cardíaca (Eje corto)	873 algoritmos FDA; encuesta ESR (572 radiólogos)
Precisión	90.2 % de precisión en clasificación	AUC: 93.2 % (Gliomas) y 89.6 % (Mama)		Alto coeficiente Dice en segmentación	AUC >0.90 (Viz.ai); Sensibilidad >90 % (Aidoc)
Limitaciones	Escasez de datos médicos anotados	Sesgos algorítmicos y «AI drift» (deriva)		Sobreajuste en bases de datos pequeñas	Solo 2 % de adopción plena en EE.UU.; 80 % desconoce regulaciones

4. Aplicaciones Reales

4.1. Casos de Implementación

La implementación de CNN en el entorno clínico cuenta con evidencia documentada en múltiples especialidades (Laurent, 2025):

4.1.1. Viz.ai — Detección de Accidentes Cerebrovasculares

Con 13 algoritmos autorizados por la FDA y despliegue en más de 1,600 hospitales, Viz.ai utiliza CNN para detectar oclusiones de grandes vasos con un AUC superior a 0.90, reduciendo el tiempo de inicio del tratamiento en aproximadamente 66 minutos.

4.1.2. Mirai — Predicción de Riesgo de Cáncer de Mama

Desarrollado por el MIT Jameel Clinic, este modelo basado en CNN predice el riesgo de cáncer de mama a 5 años a partir de mamografías, con un C-index entre 0.69 y 0.78 validado prospectivamente en 5 países. Su uso en el Mount Auburn Hospital ha permitido personalizar los intervalos de cribado.

4.1.3. Aidoc — Hemorragia Intracraneal

El sistema Aidoc emplea CNN para la detección de hemorragia intracraneal aguda con sensibilidad superior al 90 %, funcionando como triaje automático que prioriza casos críticos en la lista de trabajo del radiólogo.

4.1.4. Qure.ai — Nódulos Pulmonares

La plataforma qCT-Lung, autorizada por la FDA, utiliza CNN para detectar y segmentar nódulos pulmonares en tomografías de tórax, facilitando el cribado de cáncer de pulmón a gran escala.

4.1.5. Shockmatrix — Triage en Trauma

En un ensayo con 1,292 casos de trauma en Grenoble, Francia, el sistema basado en CNN falló en 20 pacientes que los médicos detectaron, mientras que los médicos fallaron en 21 que la IA identificó, demostrando el valor complementario de la IA como herramienta de apoyo.

5. Limitaciones y Desafíos Éticos

5.1. Sesgo y Generalización

Los modelos entrenados en poblaciones homogéneas (ej. predominantemente caucásicas) pueden fallar en otras demografías, y herramientas validadas con equipos de un fabricante específico pueden perder precisión con otros. Incluso algoritmos con 95 % de precisión en un hospital pueden caer a un 80 % en otro si difieren los protocolos de imagen o el posicionamiento del paciente.

5.2. Regulación e IA Adaptativa

La FDA y la MDR europea aprueban versiones estáticas de cada algoritmo; cualquier actualización (reentrenamiento, ajuste de umbral) requiere una nueva autorización. La FDA ha propuesto un enfoque de “ciclo de vida total del producto” para permitir actualizaciones controladas, pero los protocolos detallados aún están en desarrollo, lo que frena la adopción de IA que aprenda continuamente.

5.3. Interpretabilidad y Confianza

Muchos modelos de deep learning son “cajas negras” que producen un puntaje o mapa de calor sin explicar su razonamiento. Métodos de IA Explicable (XAI) como mapas de saliencia se están incorporando, pero los radiólogos frecuentemente los encuentran insuficientes para diagnósticos sensibles como tumores cerebrales.

5.4. Responsabilidad Legal

En la mayoría de jurisdicciones, el radiólogo que firma el reporte es legalmente responsable, incluso si la IA contribuyó al error. Esta incertidumbre genera temor a demandas por mala praxis y obliga a los especialistas a verificar cada hallazgo crítico de la IA, reduciendo las ganancias de velocidad.

5.5. Escalabilidad

El entrenamiento de redes profundas depende de GPUs de alto costo y de datasets masivos cuyo etiquetado requiere expertos. Para clínicas pequeñas, los costos de adquisición, integración y capacitación pueden ser prohibitivos.

6. Conclusiones

6.1. Síntesis de hallazgos

Las CNN han demostrado eficacia clínica comprobada: AUC del 93.2 % en clasificación de gliomas, 89.6 % en detección de cáncer de mama y sensibilidad superior al 90 % en hemorragias intracraneales. U-Net se ha consolidado como estándar para segmentación y el aprendizaje por transferencia desde ImageNet ha permitido superar la escasez de datos médicos. A mediados de 2025, 873 algoritmos de IA en radiología han sido autorizados por la FDA (Laurent, [2025](#)).

6.2. Valoración crítica

Pese a la alta precisión, la adopción plena apenas alcanza el 2 % en EE.UU. El problema de la “Caja Negra” persiste como barrera de confianza, y los sesgos algorítmicos por falta de diversidad en los datos podrían perpetuar desigualdades. La IA debe funcionar como Inteligencia Aumentada: un copiloto que complementa al especialista.

6.3. Perspectivas futuras

1. **IA Explicable (XAI):** Comprender qué regiones de la imagen influyeron en el diagnóstico.
2. **Modelos Multimodales:** Integración de imagen, historial clínico y laboratorio para diagnósticos transversales (Laurent, [2025](#)).
3. **IA Adaptativa:** Marcos regulatorios que permitan actualizar modelos sin requerir una nueva autorización completa.
4. **Aprendizaje Federado:** Entrenamiento distribuido entre hospitales sin compartir datos privados.

La colaboración entre radiólogos, desarrolladores y reguladores será decisiva para una implementación equitativa, segura y efectiva.

Referencias

- Laurent, A. (2025). *AI in Radiology: Trends in 2025* [IntuitionLabs. Última actualización: 20 de marzo de 2026]. Consultado el 29 de marzo de 2026, desde <https://intuitionlabs.ai/articles/ai-radiology-trends-2025>
- Menchú López, W. E. (2025). Inteligencia Artificial en Radiología: Una Revisión Narrativa del Estado Actual, Aplicaciones Clínicas y Perspectivas Futuras [Centro Universitario de Occidente - USAC]. *Revista Médica CUNOC*. <https://cienciacunoc.org>
- Pérez-Pelegrí, M., Monmeneu, J. V., López-Lereu, M. P., & Moratal, D. (2023). Convolutional Neural Networks for Segmentation in Short-Axis Cine Cardiac Magnetic Resonance Imaging: Review and Considerations. En Ş. Öztürk (Ed.), *Convolutional Neural Networks for Medical Image Processing Applications* (pp. 1-33). CRC Press. <https://doi.org/10.1201/9781003215141>
- Seeram, E., & Kanade, V. (2024). *Artificial Intelligence in Medical Imaging Technology: An Introduction*. Springer Nature Switzerland AG. <https://doi.org/10.1007/978-3-031-64049-0>
- Shin, H.-C., Roth, H. R., Gao, M., Lu, L., Xu, Z., Nogues, I., Yao, J., Mollura, D., & Summers, R. M. (2016). Deep Convolutional Neural Networks for Computer-Aided Detection: CNN Architectures, Dataset Characteristics and Transfer Learning. *IEEE Transactions on Medical Imaging*, 35(5), 1285-1298. <https://doi.org/10.1109/TMI.2016.2528162>